혈액 수치와 체질량지수로 1년 뒤 당뇨 진행을 예측할 수 있는가

검진표연구소 · 10101 홍길동 · 10102 김영희 · 10103 이철수

당곡고등학교 데이터 과학 팀 프로젝트 · 2026

선생님이 만든 가상 팀의 샘플 · 데이터와 수치는 실제 계산값

저장소

요약

연구 질문: 혈액 생화학 수치와 체질량지수로 1년 뒤 당뇨 진행 정도를 예측할 수 있는가

데이터와 방법: Efron 외(2004) 당뇨 환자 442명 · 체질량지수와 중성지방 로그값으로 진행 점수를 예측하는 선형 회귀를 기준선(평균 모델)과 비교

핵심 결과: MAE 44.0점, 기준선 64.0점보다 오차 31% 감소 · R^2 0.452

결론: **예측은 가능하지만 진행 정도 차이의 절반에 못 미침 · 이 데이터에서 그 설명력은 혈당보다 체질량지수·중성지방에서 나옴**

1. 서론

건강검진표에는 콜레스테롤·중성지방·혈당 같은 혈액 수치와 체질량지수가 적혀 있다. 그러나 이 수치들이 1년 뒤 당뇨 진행을 얼마나 알려 주는지는 검진표만으로 알 수 없다. 이 연구는 혈액 생화학 수치와 체질량지수로 1년 뒤 당뇨 진행 정도를 예측할 수 있는가를 밝히고자 한다. Efron 외(2004)의 당뇨 환자 442명 데이터에서 체질량지수와 중성지방 로그값으로 선형 회귀를 만들고, 후보 모델 5종을 평균 모델(기준선)과 비교하였다. 그 결과 혈당보다 체질량지수와 중성지방이 진행을 더 잘 알려 주었고, HDL이 높을수록 진행 점수가 낮았으며, 급격히 진행한 환자는 낮게 예측되었다.

2. 데이터

- Efron 외(2004) 당뇨 연구 데이터 **442행 · 11열**
- 입력: 체질량지수 bmi(18.0~42.2) · 중성지방 로그값 ltg(3.26~6.11)
- 예측: 1년 뒤 진행 점수 progression(25~346점)
- 결측값 0개 · 250점 이상 **65명(14.7%)**도 실제 측정값이라 유지
- 진행 점수는 왜도 **0.44**라 로그 변환 안 함 · ltg는 로그값 그대로

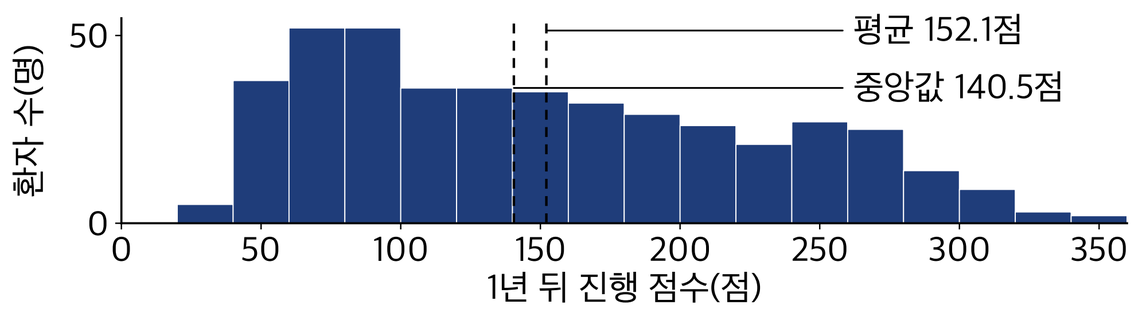


그림 1. 진행 점수 분포(442명). 높은 점수 쪽으로 약하게 치우침

3. 방법

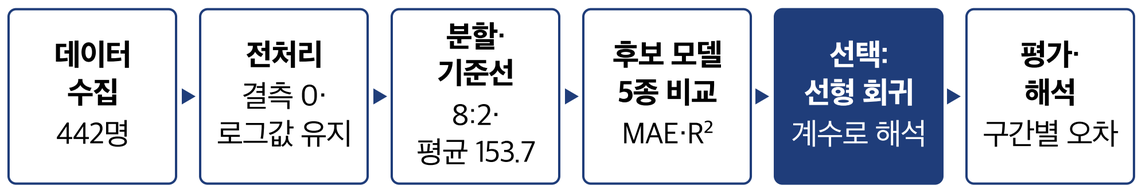


표 1. 후보 모델 비교(입력 bmi·ltg, 시험 89명)

모델	시험 MAE(점)	R^2
평균 모델(기준선)	64.0	-0.012
선형 회귀(선택)	**44.0**	**0.452**
k-NN 회귀(k=5)	44.7	0.379
결정 트리 회귀(깊이 4)	44.9	0.436
랜덤 포레스트 회귀(300그루)	43.9	0.420
XGBoost 회귀(기본값)	50.7	0.196

- 랜덤 포레스트와 MAE 차이 **0.07점**, R^2는 선형 회귀가 가장 높음
- 계수로 답을 읽음: 체질량지수 1당 **7.9점**, 중성지방 로그값 1당 **51.3점**
- **MAE:** 예측과 실제 진행 점수의 평균 차이(점)
- **R^2:** 평균 모델보다 줄인 오차의 비율

4. 결과

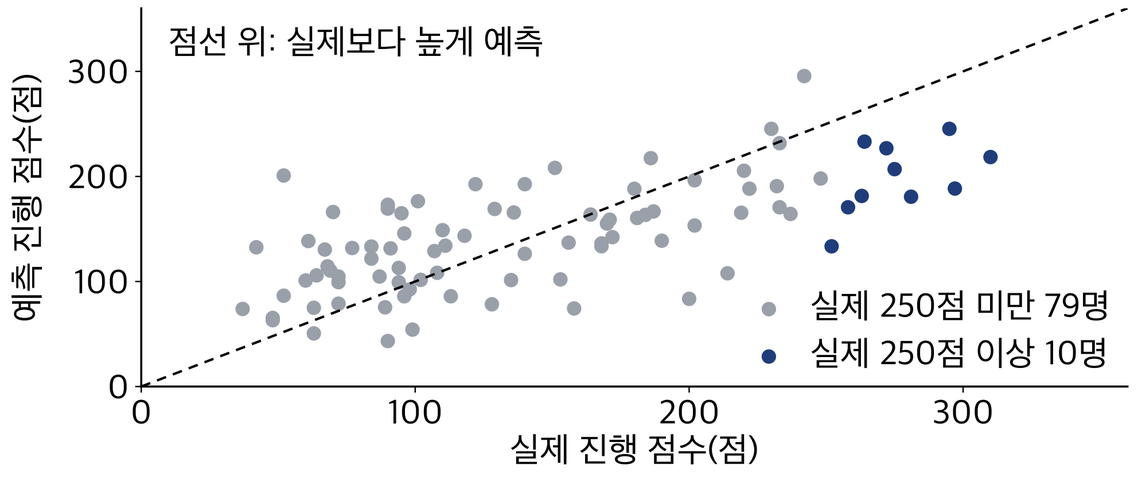


그림 2. 실제 대 예측 진행 점수(시험 89명). 실제 250점 이상 10명(남색)은 모두 점선 아래로, 실제보다 낮게 예측

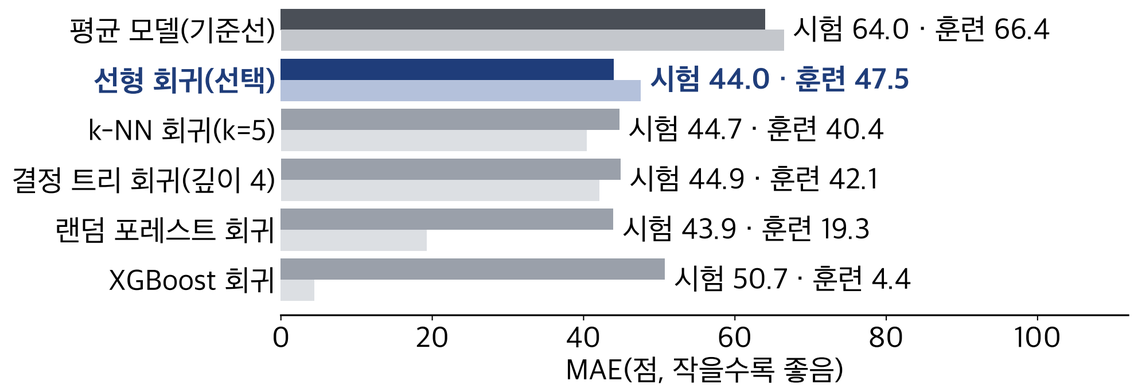


그림 3. 모델별 MAE(진한 막대 시험 89명, 옅은 막대 훈련 353명). XGBoost는 훈련·시험 오차 차이가 가장 큼

44.0
선형 회귀 MAE(점)

64.0
기준선 MAE(점)

0.452
선형 회귀 R^2

5. 논의

1. **이 데이터에서는 혈당보다 체질량지수·중성지방이 더 잘 알려 줌**
   진행 점수와의 상관계수: 혈당 **0.38**, 체질량지수 **0.59**, 중성지방 **0.57**
2. **이 데이터에서는 HDL이 높은 환자의 진행 점수가 낮음**
   HDL 하위 25% 평균 **189.0점**, 상위 25% **107.2점**
3. **이 데이터에서는 급격히 진행한 환자를 미리 알아보기 어려움**
   실제 250점 이상 10명 모두 낮게 예측(열 개 모델 평균 **72.4점** 낮음)

6. 결론과 한계

이 데이터에서 체질량지수와 중성지방으로 1년 뒤 진행을 어느 정도 예측할 수 있으나, 진행 정도 차이의 절반에 못 미침

- 442명 한 연구 집단 · 시험 데이터 한 번만 나눔(교차검증 미실시)
- sex의 뜻·측정 단위·진행 점수 산정 방법이 출처에 없음
- 개인의 진행 예측이나 치료 결정에 사용 불가
- **향후 연구:** 생활 습관 열이 있는 데이터 · k겹 교차검증

참고문헌 [1] Efron, B., Hastie, T., Johnstone, I., & Tibshirani, R. (2004). Least Angle Regression. *The Annals of Statistics*, 32(2), 407-499. 데이터 www4.stat.ncsu.edu/~boos/var.select/diabetes.html, 2026-10-15 접근 · 원래 척도 사본 scikit-learn load_diabetes(scaled=False)(BSD-3)
[2] 소프트웨어: Python 3.11, pandas 2.3.3, NumPy 1.26.4, scikit-learn 1.8.0, xgboost 3.2.0, Streamlit 1.53.1, matplotlib 3.10.8 · Claude Fable 5.1(Anthropic)
생성형 AI 활용: Claude Fable 5.1(Anthropic)로 코드 작성·해석 반론 요청·문구 다듬기, 주제 선정·해석·결론은 팀이 작성

모든 수치는 code/check.py로 다시 계산할 수 있음 · 저장소 github.com/greatsong/ds-sample-5-biochem · 앱 greatsong.github.io/ds-sample-5-biochem

앱