혈액 수치와 체질량지수로 1년 뒤 당뇨 진행을 예측할 수 있는가

검진표연구소 · 10101 홍길동 · 10102 김영희 · 10103 이철수

당곡고등학교 데이터 과학 팀 프로젝트 · 2026

선생님이 만든 가상 팀의 샘플 · 데이터와 수치는 실제 계산값

저장소

1. 서론

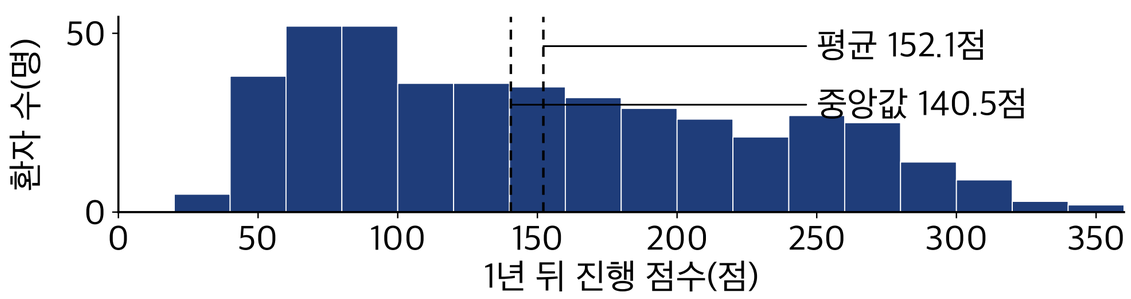
연구 질문: 혈액 수치와 체질량지수로 1년 뒤 당뇨 진행을 예측할 수 있는가

- 생명과학 시간에 배운 혈당·지질 대사에서 생긴 질문
- 진행 점수와의 상관계수: 혈당 **0.38**, 체질량지수 **0.59**, 중성지방 **0.57**
- 뇌졸중 분류(걸린다·안 걸린다)와 달리 진행 정도를 숫자로 예측

2. 데이터

출처·크기: Efron 외(2004) 당뇨 연구 데이터 · **442행 · 11열** · 결측값 0개

사용한 열	뜻	범위
bmi	체질량지수(입력)	18.0~42.2
ltg	중성지방 로그값(입력)	3.26~6.11
progression	1년 뒤 진행 점수(예측할 값)	25~346점



진행 점수 분포(442명): 평균 152.1점, 중앙값 140.5점

- 250점 이상 **65명(14.7%)**도 실제 측정값이라 이상값으로 빼지 않음
- 왜도 **0.44**로 치우침이 작아 로그 변환하지 않음
- sex는 어느 쪽이 남자인지 출처에 없어 계수를 해석하지 않음

3. 방법

수집(442명) → 변수 선택(bmi·ltg) → 전처리(이상값 유지) → 분할(8:2) → 기준선(평균) → 후보 5종 비교 → 선택(선형 회귀) → 평가(MAE·R^2) → 해석(잔차)

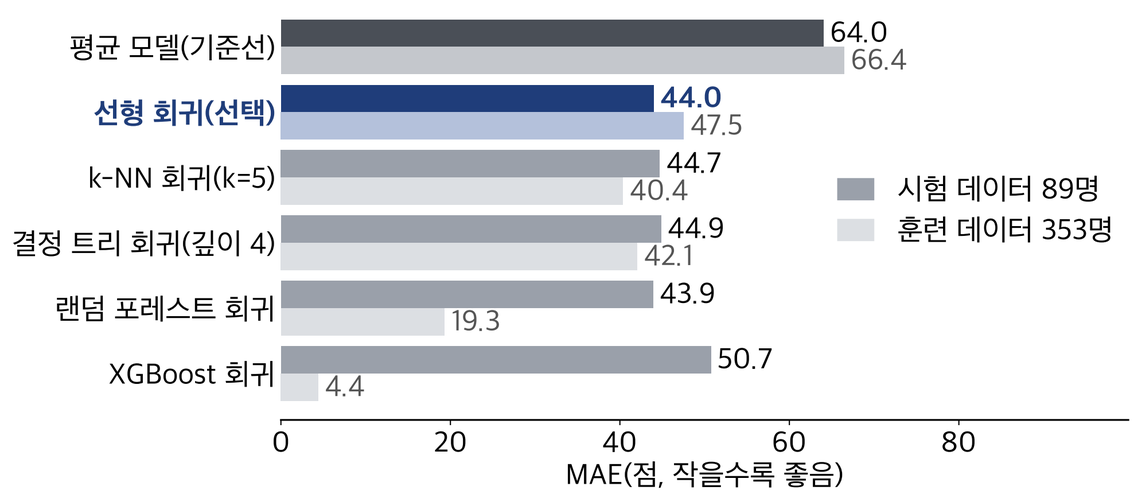
후보 모델(입력 bmi·ltg, 예측 진행 점수)	시험 MAE	R^2
평균 모델(기준선)	64.0점	-0.012
선형 회귀(선택)	**44.0점**	**0.452**
k-NN 회귀(k=5)	44.7점	0.379
결정 트리 회귀(깊이 4)	44.9점	0.436
랜덤 포레스트 회귀(300그루)	43.9점	0.420
XGBoost 회귀(기본값)	50.7점	0.196

- 랜덤 포레스트와 MAE 차이는 **0.07점**, R^2는 선형 회귀가 가장 높음
- 계수로 "체질량지수 1 오르면 7.9점"처럼 답을 읽을 수 있어 선택

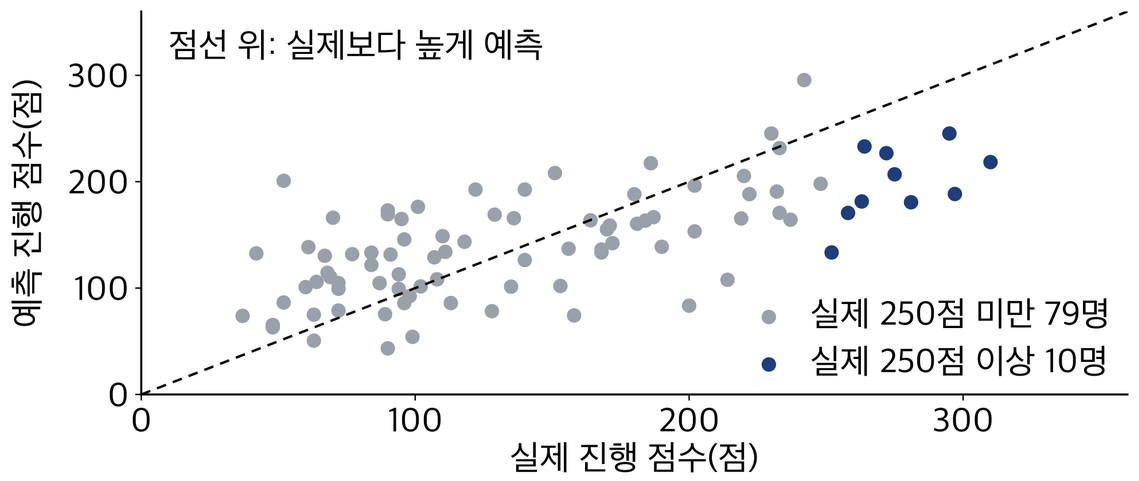
모델	원리	장점	단점	이런 상황에 좋다	우리 데이터 결과
선형 회귀(선택)	**오차가 가장 작은 직선(평면)**	**계수로 영향의 크기 해석**	**곡선 관계에 약함**	**이유를 설명해야 할 때**	**MAE 44.0점 R^2 0.452**
랜덤 포레스트(비교 1)	트리 여러 개의 예측을 평균	예측이 안정적	이유 해석이 어려움	관계가 복잡할 때	MAE 43.9점 R^2 0.420
XGBoost(비교 2)	트리를 차례로 더해 오차를 줄임	표 데이터에서 정확도 높음	작은 데이터를 외우기 쉬움	데이터가 많을 때	MAE 50.7점 R^2 0.196

- **MAE:** 예측 진행 점수가 실제와 평균 몇 점 차이 나는가
- **R^2:** 평균 모델보다 오차를 얼마나 줄였는가(1에 가까울수록 좋음)

4. 결과



XGBoost는 훈련 MAE 4.4점, 시험 MAE 50.7점으로 훈련 데이터를 외운 것에 가까움



선형 회귀(bmi + ltg) 예측. 실제 250점 이상인 10명은 모두 점선 아래(낮게 예측)

44.0점
선형 회귀 MAE

64.0점
기준선(평균 모델) MAE

0.452
선형 회귀 R^2

5. 해석과 결론

- **혈당보다 체질량지수·중성지방이 1년 뒤 진행을 더 잘 알려 줌**
  진행 점수와의 상관계수: 혈당 0.38 · 체질량지수 0.59 · 중성지방 0.57
- **콜레스테롤은 총량보다 종류에 따라 다름**
  총콜레스테롤 상관 0.21 · HDL -0.39, HDL 하위 25% 평균 189.0점 · 상위 25% 107.2점
- **급격히 진행한 환자는 검진 수치로 미리 알기 어려움**
  실제 250점 이상 시험 환자 10명 모두 낮게 예측(평균 72.4점 낮음), 실제 310점 → 예측 207.4점
- **변수 추가 실험:** 열 개 모델과 R^2 차이 0.0003, 두 수치로 거의 같은 설명력

이 데이터에서 1년 뒤 진행은 체질량지수와 중성지방으로 어느 정도 예측되지만, 설명력은 절반에 못 미치고 급격한 진행은 놓침

6. 한계와 향후 연구

- 열 개를 모두 넣어도 진행 점수 차이의 약 **55%**는 설명하지 못함
- 예측 206.5점·206.6점으로 거의 같은 두 환자의 실제 점수는 **52점·297점**
- **오용 주의:** 개인의 병 진행 예측이나 치료 결정에 사용하면 안 됨
- **더 해 볼 것:** 생활 습관 열이 있는 데이터, 시험 데이터를 여러 번 나눈 평가
- **교과·진로:** 생명과학(혈당·지질 대사)·화학·체육 · 임상병리사·의학 연구·보건 데이터 분석
- **배운 점:** "관계없다"와 "더 보태는 설명력이 작다"는 다른 주장임

데이터: Efron, Hastie, Johnstone, Tibshirani (2004). Least Angle Regression. The Annals of Statistics, 32(2), 407-499

원자료 www4.stat.ncsu.edu/~boos/var.select/diabetes.html · 참고: 데이터 출처·소프트웨어는 README 참고문헌

저장소 github.com/greatsong/ds-sample-5-biochem · 앱 greatsong.github.io/ds-sample-5-biochem · 수치는 code/check.py로 재계산 가능

앱